



UNIVERSITÀ DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

Corso di Laurea Magistrale in Informatica

**Cross-Modal Vulnerability: Exploiting
Fusion Fragility in Multimodal
Misinformation Detection with
Adversarial Examples**

Supervisor

Prof. Maurizio Atzori

Candidate

Davide Cocco

ACADEMIC YEAR 2024/2025

Abstract

Il crescente uso di modelli vision-language per compiti complessi, come la rilevazione della disinformazione, solleva questioni critiche riguardo la loro robustezza. Sebbene la letteratura abbia analizzato le vulnerabilità unimodali, l'impatto combinato delle perturbazioni coordinate su testo e immagine rimane poco esplorato.

Questa tesi indaga la robustezza di un modello OpenCLIP ViT-B/16 (variante Themis) in uno scenario white-box, confrontando l'impatto di attacchi unimodali e multimodali. Utilizzando il dataset ReCOVery, sono state applicate perturbazioni visive impercettibili tramite il Projected Gradient Descent (PGD) e perturbazioni testuali semanticamente coerenti generate da un modello linguistico leggero: Phi-3:instruct.

I risultati evidenziano una forte asimmetria della vulnerabilità: il modello si è dimostrato resiliente alle sole perturbazioni testuali, con un Attack Success Rate (ASR) = 12.1%, ma estremamente fragile agli attacchi visivi, i quali hanno ottenuto un ASR = 86.4%. L'attacco multimodale congiunto ha ulteriormente amplificato il fallimento, raggiungendo un ASR del 99.2%.

Tale incremento, leggermente superiore a un semplice effetto additivo, dimostra un'interazione non lineare e un effetto catalitico, indicando che il meccanismo di fusione multimodale stesso introduce una vulnerabilità critica. L'analisi qualitativa ha inoltre confermato la minaccia realistica di questi attacchi, capaci di validare notizie false e censurare quelle vere, e la loro fattibilità anche con risorse computazionali limitate.

Indice

1	Introduzione	1
1.1	Studio del problema	2
1.2	Obiettivi e metodologia	2
1.3	Gap di ricerca	4
2	Stato dell'Arte	7
2.1	Fondamenti teorici	7
2.1.1	Apprendimento multimodale e vulnerabilità dei modelli .	8
2.1.2	Robustezza e rilevazione della disinformazione	9
2.2	Attacchi avversari unimodali	11
2.2.1	Attacchi su immagini	11
2.2.2	Attacchi su testo	12
2.2.3	Limiti degli approcci unimodali	13
2.3	Attacchi avversari multimodali	13
2.3.1	Perché il multimodale è diverso	13
2.3.2	Threat model tipici	14
2.3.3	Categorie di attacco multimodale	15
2.3.4	Metriche di valutazione	16
2.3.5	Esempi applicativi e risultati	16
2.4	Contromisure e difese	17
2.4.1	Tecniche di robustezza dei modelli	17
2.4.2	Trade-off tra accuratezza e robustezza	17
2.4.3	Esempi applicativi e risultati	18
2.5	Discussione e Posizionamento della Tesi	18
2.5.1	Limitazioni e sfide aperte	18
2.5.2	Posizionamento della Tesi	19

3	Materiali e Metodi	21
3.1	Framework e strumenti software	21
3.1.1	PyTorch e gestione dei modelli	21
3.1.2	OpenCLIP e architettura multimodale	22
3.1.3	Ollama e modello linguistico Phi-3:instruct	22
3.2	Motivazioni metodologiche	23
3.3	Dataset e pre-processing	24
3.4	Perturbazioni delle immagini	24
3.5	Perturbazioni testuali e prompt engineering	26
3.6	Metriche di valutazione	27
3.7	Setup sperimentale e riproducibilità	29
4	Esperimenti e Risultati	31
4.1	Impostazione generale degli esperimenti	31
4.2	Pipeline sperimentale	32
4.3	Parametri di attacco	33
4.3.1	Perturbazioni visive	33
4.3.2	Perturbazioni testuali	34
4.4	Risultati quantitativi	35
4.4.1	Metriche di classificazione	35
4.4.2	Metriche di robustezza	36
4.5	Analisi qualitativa	36
4.6	Esempi qualitativi	36
4.6.1	Struttura dei risultati	37
4.6.2	Esempi positivi	38
4.6.3	Limitazioni	41
4.7	Discussione dei risultati	42
4.7.1	L'asimmetria della vulnerabilità: dominanza dell'attacco visivo	43
4.7.2	Oltre l'additività: l'effetto catalitico dell'attacco multimodale	43
4.7.3	Implicazioni qualitative: la minaccia della doppia inversione	44
4.7.4	Considerazioni sulla metodologia	45
5	Conclusioni e Sviluppi Futuri	51
5.1	Sintesi dei risultati	51

5.2	Sviluppi futuri	52
5.3	Riflessioni conclusive	53
References		58

Capitolo 1

Introduzione

Negli ultimi anni, l'intelligenza artificiale ha assistito a una rapida evoluzione dei modelli multimodali, capaci di integrare e ragionare simultaneamente su informazioni provenienti da più fonti, come immagini, testo, audio e video. La capacità di combinare modalità differenti ha aperto nuove prospettive nel campo della visione artificiale e del linguaggio naturale, consentendo prestazioni notevoli in compiti come il visual question answering, il cross-modal retrieval e la fake news detection [1].

Un punto di svolta è stata l'introduzione del paradigma language-image pre-training, che ha reso possibile l'apprendimento di rappresentazioni comuni tra visione e linguaggio. Architetture come CLIP [18] hanno dimostrato come sia possibile addestrare due encoder, uno testuale e uno visivo, a condividere uno spazio semantico, migliorando notevolmente la trasferibilità e l'adattabilità dei modelli in scenari zero-shot e aprendo la strada a nuovi modelli vision-language sempre più generali e versatili.

L'integrazione multimodale, tuttavia, porta con sé anche nuove sfide come la **robustezza** dei modelli multimodali che rappresenta oggi un tema centrale. Sebbene tali modelli si mostrino più flessibili e performanti rispetto alle controparti unimodali, resta da comprendere quanto siano affidabili in presenza di perturbazioni intenzionali o manipolazioni sottili degli input, siano esse testuali, visive o congiunte [28, 2]. Comprendere queste vulnerabilità è cruciale, soprattutto in contesti sensibili come la rilevazione automatica della disinformazione, dove errori sistematici possono causare errori significativi.

1.1 Studio del problema

Questo lavoro si inserisce nello studio della robustezza dei modelli multimodali in situazioni avverse, con un focus particolare sugli attacchi che colpiscono sia il testo che l'immagine. L'obiettivo principale è capire se e in che misura la componente multimodale possa aumentare o diminuire la vulnerabilità di un modello rispetto agli attacchi unimodali, in linea con le analisi di VLAttack. [28] e CAMOUFLAGE [2].

In particolare, il lavoro cerca di rispondere alle seguenti domande di ricerca:

- La fusione di più modalità rende il modello più resistente o, al contrario, più suscettibile agli attacchi avversari?
- Esistono differenze significative nella probabilità che il modello venga ingannato quando lavora su un'unica modalità rispetto a quando ne utilizza più di una?

Per esplorare questi aspetti, il modello vision-language scelto è stato sottoposto a perturbazioni controllate su immagini e testi, sia separatamente che insieme. L'analisi si è focalizzata in particolare su quei casi in cui, in modo unimodale, il modello riesce a mantenere una classificazione corretta, mentre in modalità multimodale si notano errori o cambiamenti nella classificazione. Questa differenza di comportamento è al centro del problema studiato, poiché evidenzia il ruolo dell'interazione cross-modale nel comportamento complessivo del modello e la possibile insorgenza di fenomeni di amplificazione dell'errore.

1.2 Obiettivi e metodologia

Gli obiettivi principali del lavoro sono i seguenti:

1. Analizzare il comportamento di un modello multimodale sottoposto ad attacchi avversari unimodali e multimodali;
2. Quantificare, attraverso metriche di accuratezza e robustezza, la variazione delle prestazioni in funzione del tipo di perturbazione;

Per valutare in modo sistematico il comportamento del modello in scenari realistici, gli esperimenti sono stati condotti sul dataset di test di **ReCOVery** [30],

già impiegato nello studio *Is it fake or not?* [15] per la valutazione del framework Themis [29]. Questo dataset, composto da coppie immagine-testo derivate da articoli di notizie reali e false, rappresenta un benchmark consolidato per la rilevazione multimodale della disinformazione. L'utilizzo esclusivo del test set (283 campioni) ha permesso di evitare fenomeni di overfitting e di garantire una vera valutazione della robustezza del modello rispetto a perturbazioni unimodali e multimodali.

Per la generazione delle perturbazioni visive è stato adottato l'attacco **Projected Gradient Descent (PGD)** [13], scelto dopo una valutazione empirica di diversi algoritmi disponibili nella libreria *torchattacks*, tra cui Fast Gradient Sign Method (FGSM) [9] e OnePixel [22]. PGD si è dimostrato il metodo più versatile nel trovare un equilibrio tra complessità computazionale e qualità delle perturbazioni. Offre un controllo preciso sui parametri e riesce a creare alterazioni visive praticamente invisibili a occhio nudo, a differenza degli altri algoritmi esplorati reputati più invasivi.

Per la perturbazione testuale è stato impiegato un modello linguistico di piccole dimensioni, **Phi-3:instruct**, scelto per l'ottimo compromesso tra efficienza e qualità del testo generato. La scelta è stata guidata dalla necessità di operare in un contesto di risorse fortemente limitate, che ha imposto l'esecuzione del modello principale in CPU e reso impraticabile l'impiego di modelli linguistici più complessi. Tale vincolo ha influenzato la pipeline sperimentale, orientandola verso soluzioni leggere e modulari.

Nonostante le risorse ridotte, il modello ha mostrato buone capacità di parafrasi, generando riscritture semanticamente coerenti. Tuttavia, in alcune circostanze, produceva testi strutturati o codificati (ad esempio in linguaggi di markup), causando errori di elaborazione. Per ovviare a questo problema, è stata successivamente eseguita una seconda sperimentazione in cui le perturbazioni testuali sono state filtrate in base alla similarità semantica, così da considerare solo le riscritture effettivamente valide.

Pertanto, è stato possibile generare perturbazioni efficaci in grado di alterare le classificazioni del modello multimodale anche con poca disponibilità di calcolo.

Gli esperimenti hanno seguito una pipeline strutturata in più fasi:

1. Esecuzione di una predizione del modello con dati puliti (**clean**);

2. Applicazione delle perturbazioni su testo e immagine solo per i campioni correttamente classificati;
3. Nuova inferenza con solo testo corrotto (**text corruption**), solo immagine corrotta (**image corruption**) e entrambi corrotti (**multimodal corruption**);
4. Calcolo delle metriche di accuratezza, precisione, richiamo e F1-score per ciascuna configurazione;
5. Calcolo delle metriche di robustezza (Δ **Accuracy**, **Flip rate**, **Attack Success Rate**) per confrontare l'efficacia dei diversi tipi di attacco.

In figura 4.1 è disponibile una visione più accurata della pipeline di esecuzione.

I risultati sperimentali mostrano che, unimodalmente, il modello mantiene una certa robustezza alle perturbazioni testuali leggere, con un impatto limitato sull'accuratezza complessiva.

Al contrario, le perturbazioni applicate alle immagini producono già un degrado marcato delle prestazioni, segnalando una maggiore vulnerabilità della componente visiva. Tuttavia, è nel caso multimodale che la fragilità risulta essere maggiore: combinando modifiche minime su entrambe le modalità, la quasi totalità delle predizioni corrette sui dati puliti viene invertita.

Ciò indica che, pur ampliando la capacità di comprensione semantica, la componente multimodale introduce un'interazione non lineare tra rappresentazioni visive e linguistiche che amplifica gli effetti delle perturbazioni rendendo il sistema più vulnerabile.

Tutti gli script utilizzati per l'esecuzione degli esperimenti, inclusa la pipeline di generazione delle perturbazioni e di calcolo delle metriche, sono disponibili pubblicamente nella seguente repository GitHub.

1.3 Gap di ricerca

Nonostante la crescente attenzione verso la sicurezza e l'affidabilità dei modelli multimodali, la letteratura mostra ancora diverse lacune:

- La maggior parte degli studi si concentra su attacchi unimodali, trascurando l'interazione e la propagazione cross-modale [28, 1];

- Mancano benchmark consolidati e metriche standard per valutare la robustezza multimodale in scenari realistici [2];
- Non è ben chiaro come e quando le perturbazioni congiunte influenzino le decisioni del modello o amplifichino i loro effetti a vicenda [25].

Queste considerazioni motivano la necessità di indagare più a fondo i meccanismi di vulnerabilità e di interazione tra testo e immagine, ponendo le basi per lo sviluppo di modelli multimodali più stabili, interpretabili e resistenti a perturbazioni cross-modali.

Capitolo 2

Stato dell'Arte

Come accennato nel capitolo precedente, l'aumento dell'uso di modelli multimodali ha sollevato importanti interrogativi sulla loro robustezza. In questo capitolo, è presente l'analisi dello stato attuale della ricerca per fornire il contesto teorico e sperimentale necessario a inquadrare le domande di ricerca di questa tesi.

L'obiettivo è duplice: da un lato, si vogliono rafforzare le basi teoriche dell'apprendimento multimodale e delle sue vulnerabilità; dall'altro, si propone di analizzare in modo sistematico la letteratura sugli attacchi avversari, partendo da quelli unimodali (su testo o immagine) fino ad arrivare alle più recenti e complesse strategie multimodali. Questa rassegna permetterà di mappare con precisione i gap di ricerca evidenziati in 1.3.

2.1 Fondamenti teorici

In questa sezione vengono illustrati i concetti fondamentali necessari per comprendere gli attacchi avversari multimodali. L'obiettivo è fornire un quadro teorico unitario che introduca i principi dell'apprendimento multimodale, le vulnerabilità che ne derivano e il loro impatto su applicazioni sensibili come la rilevazione automatica della disinformazione.

2.1.1 Apprendimento multimodale e vulnerabilità dei modelli

I moderni sistemi di intelligenza artificiale si basano sull'apprendimento automatico, ovvero sulla capacità di un modello di apprendere schemi dai dati e di generalizzare su nuovi esempi. I modelli tradizionali operavano in modo unimodale, ossia utilizzando una sola tipologia di input (testo, immagine o audio). I modelli multimodali, invece, integrano informazioni provenienti da più tipologie di dati per ottenere una rappresentazione più ricca e coerente del contenuto.

Un esempio emblematico di questa evoluzione è rappresentato da CLIP [18], che ha introdotto uno spazio di rappresentazione condiviso tra linguaggio e visione. Tale spazio consente di mettere in corrispondenza descrizioni testuali e contenuti visivi, permettendo al modello di generalizzare su compiti mai visti prima: zero-shot learning. In figura 2.1 si può notare l'ottima capacità di CLIP di generalizzare rispetto a modelli supervisionati.

Questa integrazione tra modalità ha aperto la strada a numerose applicazioni, ma anche a nuove vulnerabilità dovute all'interazione tra le modalità stesse. Le prime analisi sistematiche sulla fragilità dei modelli di apprendimento auto-




Figura 2.1: Robustezza e generalizzazione di CLIP rispetto ai modelli supervisionati. A sinistra, l'asse delle x rappresenta l'accuratezza media (top-1) su classi di ImageNet, mentre l'asse y mostra l'accuratezza media su sette dataset che introducono variazioni naturali di distribuzione. A destra viene illustrato un esempio specifico per la classe "banana", comune a cinque dei sette dataset analizzati. Dati tratti e adattati da CLIP [18].

matico risalgono a lavori come quello di Goodfellow et al. [9], che introdusse

il Fast Gradient Sign Method. Tale approccio dimostrò che è possibile indurre un modello di classificazione a commettere errori applicando perturbazioni minime, impercettibili all'occhio umano. Tramite la distillazione difensiva è stato possibile mitigare alcune fragilità delle reti neurali causate dalla sensibilità dei dati, ma Carlini e Wagner [3] proposero un attacco più sofisticato, in grado di ottimizzare direttamente la perturbazione necessaria a cambiare la decisione del modello con la minima alterazione dell'input. Questi studi hanno mostrato come anche modelli altamente performanti possano essere ingannati da modifiche minime, evidenziando la necessità di sviluppare metodi per analizzare e mitigare tali vulnerabilità. In figura 2.2 è presente un esempio di attacchi avversari. Nei




Figura 2.2: *Esempio di generazione di un esempio avversario con il Fast Gradient Sign Method (FGSM). Nonostante la variazione sia invisibile all'occhio umano, il modello GoogLeNet (Szegedy et al., 2014) modifica completamente la sua classificazione. Figura tratta e adattata da Goodfellow et al. [9].*

modelli multimodali, il problema si amplifica: un attacco può colpire una singola modalità (ad esempio il testo o l'immagine) oppure sfruttare le relazioni tra modalità per propagare l'errore nell'intero processo decisionale. Questo aspetto è particolarmente rilevante perché la combinazione di più fonti informative, pur migliorando l'accuratezza del modello, introduce nuove superfici d'attacco difficili da individuare e contrastare, come è dimostrato in VLAttack [28].

2.1.2 Robustezza e rilevazione della disinformazione

In Szegedy et al. [23] la robustezza di un modello è definita come la sua capacità di mantenere prestazioni affidabili anche in presenza di input manipolati o

rumorosi. Le principali strategie sviluppate per aumentare la robustezza le troviamo in Madry et al. [13]; comprendono l’adversarial training, che introduce esempi generati da attacchi in fase di addestramento per ottimizzare la resistenza del modello, e la data augmentation, che amplia la varietà dei dati di training applicando trasformazioni naturali e non avversarie, come rotazioni, parafrasi o variazioni stilistiche. Altri approcci, come i metodi ensemble di Tramèr et al. [24], combinano più modelli o viste differenti dello stesso input per ridurre la vulnerabilità complessiva.

Nel contesto dell’apprendimento multimodale, sono stati proposti anche metodi di regolarizzazione o filtraggio per ridurre bias e comportamenti indesiderati nei modelli di linguaggio e visione. Ad esempio, Safe-CLIP [17] applica tecniche di debiasing ai modelli pre-addestrati per ridurre la sensibilità verso concetti indesiderati o non sicuri, migliorando la loro affidabilità in applicazioni reali.

Uno dei domini in cui la robustezza riveste un ruolo cruciale è la rilevazione della disinformazione, come menzionato in [1]. Singhal et al. [20] dimostrano che alcuni sistemi di rilevamento delle fake news multimodale utilizzano la coerenza tra testo e immagine come segnale principale per valutare l’attendibilità di una notizia. Tuttavia, Mura et al. [15] hanno mostrato che riscritture semantiche o immagini non pertinenti possono ingannare questi sistemi, compromettendo la decisione del modello. Il framework CAMOUFLAGE [2] dimostra come riscritture guidate da LLM, pur mantenendo un’equivalenza semantica apparente, possano alterare la risposta di moduli di retrieval e comparazione in pipeline evidence-based. La tabella 2.1 riporta i risultati più descrittivi dell’approccio di Bethany et al. In sintesi, la ricerca attuale evidenzia che la difesa dei modelli mul-

Tabella 2.1: *Risultati principali riportati da CAMOUFLAGE [2]. La tabella mostra l’Attack Success Rate (ASR) e l’abbassamento delle prestazioni di retrieval su diversi sistemi di misinformation detection multimodale. I risultati evidenziano come le riscritture LLM-guidate possano compromettere pipeline evidence-based anche in setting black-box.*

Dataset	ASR (%)	Retrieval degradation (%)	Query budget
GossipCop	46.9	18.4	80
Weibo	44.3	21.7	90
PolitiFact	41.2	19.6	85

timodali non può concentrarsi su una sola modalità, ma deve tenere conto della complessità delle interazioni tra le diverse fonti. Analizzare gli attacchi avversari

multimodali non significa solo esaminare la vulnerabilità dei modelli, ma anche capire i limiti strutturali dell'integrazione multimodale e progettare architetture più robuste per applicazioni critiche.

2.2 Attacchi avversari unimodali

Prima di analizzare gli attacchi multimodali, è utile considerare i casi più semplici, cioè quelli in cui viene manipolata una sola modalità. Gli attacchi unimodali rappresentano la base concettuale e il termine di paragone fondamentale per questo studio.

2.2.1 Attacchi su immagini

Gli attacchi su immagini sono stati i primi a ricevere grande attenzione dalla comunità scientifica. L'obiettivo, in questa tipologia di attacchi, è applicare piccole perturbazioni ai pixel di un'immagine per indurre il modello a produrre una classificazione errata, pur mantenendo un aspetto visivamente identico all'originale.

Tra i metodi più noti si possono citare:

- **Fast Gradient Sign Method (FGSM)** [9], che calcola la perturbazione come il segno del gradiente della funzione di perdita rispetto all'immagine di input, generando un singolo passo di aggiornamento.
- **Projected Gradient Descent (PGD)** [13], che estende il FGSM iterando il processo di perturbazione e proiettando i risultati entro un vincolo ϵ di ampiezza massima rappresentando uno dei metodi più solidi per testare la robustezza. Questo è l'approccio che verrà utilizzato negli esperimenti di questa tesi. La scelta di PGD come attacco principale è motivata anche dalla sua efficienza computazionale.
- **DeepFool** [14], che cerca la perturbazione in grado di attraversare il confine decisionale del classificatore.
- **Carlini & Wagner (C&W)** [3], un attacco di ottimizzazione più sofisticato che minimizza esplicitamente la distanza tra l'immagine originale e quel-

la perturbata soggetta al vincolo di misclassificazione. Una versione più avanzata ed ottimale di DeepFool.

Oltre agli attacchi diretti, la letteratura ha proposto varianti più realistiche, come gli attacchi fisici, in cui la perturbazione è stampata su oggetti reali (ad esempio adesivi o pattern indossabili), per ingannare modelli di riconoscimento in ambienti concreti. Eykholt et al. dimostrano come questo sia possibile in ambienti reali [7].

2.2.2 Attacchi su testo

Anche i modelli di elaborazione del linguaggio naturale sono suscettibili a manipolazioni avversarie. A differenza delle immagini, le modifiche testuali devono rispettare vincoli di leggibilità e semantica: un testo alterato non deve sembrare artificiale per il lettore umano. Gli attacchi testuali possono avvenire sul carattere, sulla parola o sulla frase.

Tra i principali approcci:

- **HotFlip** [5], che utilizza il gradiente rispetto agli embedding per identificare i caratteri o le parole da sostituire.
- **TextFooler** [11], che seleziona parole cruciali per la classificazione e le sostituisce con sinonimi semantici, mantenendo la naturalezza del testo.
- **BAE (BERT-based Adversarial Examples)** [8], che sfrutta il mascheramento e la predizione di BERT per generare sostituzioni lessicali plausibili.
- **Generative Attacks** [2], in cui alcuni LLM vengono usati per creare parafrasi o intere riscritture mantenendo l'intento originale, ma alterando la predizione del modello target. Questo approccio è analogo a quello impiegato in questa tesi.

Li et al. [12] evidenziano che questi attacchi hanno mostrato vulnerabilità significative in diversi task NLP, dalla sentiment analysis al question answering. Essi evidenziano che anche piccole modifiche lessicali possono compromettere la generalizzazione dei modelli.

2.2.3 Limiti degli approcci unimodali

Sebbene efficaci e ampiamente studiati, gli attacchi unimodali presentano un limite intrinseco: nella realtà, i contenuti digitali raramente si presentano in forma isolata. Una notizia, un post su un social o un articolo online combinano tipicamente testo e immagini. Di conseguenza, concentrare gli sforzi su una sola modalità rischia di sottovalutare le vulnerabilità reali dei sistemi multimodali.

La transizione verso gli attacchi multimodali nasce quindi dall'esigenza di studiare modelli più complessi e realistici, capaci di integrare più fonti informative.

2.3 Attacchi avversari multimodali

Gli attacchi avversari multimodali rappresentano l'estensione naturale degli attacchi unimodali e costituiscono il focus principale di questa tesi. Rispetto agli attacchi unimodali, qui l'attaccante può sfruttare sia le vulnerabilità di ciascuna modalità, sia le vulnerabilità che emergono dall'interazione tra di esse.

2.3.1 Perché il multimodale è diverso

I modelli multimodali non sono semplicemente la somma di due modelli unimodali. Essi costruiscono rappresentazioni congiunte o collegate tra le modalità, come nel caso degli embedding condivisi introdotti da CLIP [18]. Questo approccio, pur migliorando la generalizzazione, introduce nuove superfici d'attacco:

- **Propagazione cross-modale:** una perturbazione su una modalità (ad esempio, visiva) può alterare le rappresentazioni condivise e propagarsi all'altra modalità, dimostrato in VLAttack [28];
- **Incoerenza semantica:** modificare la relazione testo-immagine o introdurre elementi fuorvianti può spingere il modello verso decisioni errate, come evidenziato da Abdali et al. [1];
- **Manipolazione della pipeline:** i moduli di retrieval e comparazione claim-evidence rappresentano ulteriori punti d'attacco, il framework CAMOUFLAGE ne è un esempio [2].

Queste vulnerabilità derivano dal fatto che i modelli multimodali si basano su uno spazio embedding condiviso e spesso utilizzano meccanismi di *cross-attention* che possono amplificare l'effetto delle perturbazioni seppur minime.

2.3.2 Threat model tipici

La letteratura sugli attacchi multimodali distingue diversi threat model, ovvero le assunzioni fatte sull'accesso e sulle capacità dell'attaccante. I più comuni sono:

- **White-box vs. Black-box:** nel caso white-box l'attaccante conosce pesi e architettura del modello, potendo calcolare gradienti e ottimizzare la perturbazione, si veda Madry et al. [13]. Nel caso black-box, ha accesso solo a output o API, come nel framework CAMOUFLAGE [2]. In figura 2.3 è riportata la pipeline seguita da Bethany et al.
- **Accesso limitato alle modalità:** in alcuni scenari l'attaccante può manipolare solo una parte dell'input (es. testo ma non immagine, o viceversa), come mostrato in VLAttack [28].
- **Vincoli pratici:** includono il numero di query disponibili o la coerenza semantica del messaggio, che rendono gli attacchi più realistici e difficili da rilevare. I vincoli sono discussi in CAMOUFLAGE [2].




Figura 2.3: *Schema pipeline CAMOUFLAGE. Schema tratto e adattato da CAMOUFLAGE [2].*

2.3.3 Categorie di attacco multimodale

Perturbazioni congiunte immagine-testo

In questa categoria, l'attaccante modifica contemporaneamente sia immagine che testo per ingannare modelli vision-language. VLAttack [28] mostra che perturbazioni coordinate possono ridurre drasticamente l'accuratezza su benchmark come Flickr30k e MSCOCO, dimostrando che i modelli multimodali sono vulnerabili anche quando una singola modalità appare coerente. Gli autori propongono inoltre un attacco trasferibile, efficace anche su modelli black-box.

Attacchi che sfruttano l'incoerenza cross-modale

Un'altra strategia consiste nel generare incoerenze tra le modalità. Ad esempio, lavori come *Is it fake or not?* [15] mostrano come la coerenza tra testo e immagine sia un segnale cruciale nella classificazione. Pertanto, anche lievi alterazioni di tale relazione (VLAttack [28], CAMOUFLAGE [2]) possono compromettere l'affidabilità del modello.

Attacchi sulla pipeline di retrieval e comparison

Molti sistemi evidence-based seguono una pipeline a tre stadi: recupero di evidenze, comparazione claim-evidence e classificazione. CAMOUFLAGE [2] dimostra che riscritture semantiche prodotte da LLM possono far recuperare evidenze meno pertinenti, compromettendo sia il retrieval sia la comparazione, con un Attack Success Rate (ASR) medio superiore al 40% e un budget di query inferiore a 100.

Prompt injection, jailbreak e attacchi su agenti multimodali

Gli agenti multimodali (es. GPT-4o, Gemini) integrano linguaggio, visione e interazione con l'ambiente. Studi recenti mostrano come attacchi di tipo prompt injection o jailbreak possano manipolare le istruzioni dell'agente inducendolo a comportamenti pericolosi, come esfiltrare dati o generare comandi malevoli, come dimostrato da Chiu et al. [4] e Wang et al. [25]. L'introduzione di modalità aggiuntive (audio, video) rende tali minacce ancora più difficili da affrontare.

2.3.4 Metriche di valutazione

Per misurare l'efficacia degli attacchi e delle difese multimodali vengono utilizzate diverse metriche, tra cui la più comune è l'Attack Success Rate (ASR).

- **Attack Success Rate (ASR)** - definita come la percentuale di esempi per i quali l'attacco riesce a modificare la decisione del modello target [28, 2]. È la metrica principale utilizzata nella maggior parte dei lavori sugli attacchi avversari, poiché quantifica direttamente l'efficacia dell'attacco.
- **Query Budget** - indica il numero medio di query necessarie per ottenere un attacco riuscito nel caso di modelli black-box, rappresentando un parametro pratico di fattibilità. È utilizzato in lavori come [2]
- **Preservazione semantica / naturalità** - valuta quanto l'input manipolato resti coerente e plausibile per un osservatore umano. Quando presente, viene stimata tramite misure di similarità tra embedding, metriche automatiche come BERTScore o valutazioni umane, ma non è standardizzata nella letteratura attuale.

Un attacco efficace deve massimizzare l'ASR minimizzando la percettibilità delle distorsioni in tutte le modalità.

2.3.5 Esempi applicativi e risultati

Per comprendere meglio l'impatto degli attacchi, la Tabella 2.2 riassume alcuni risultati quantitativi ottenuti in studi recenti. I risultati confermano che anche

Tabella 2.2: *Esempi di risultati riportati in letteratura per attacchi.*

Lavoro	Scenario	Target	ASR (%)
VLAttack 2024 [28]	Image-Text	CLIP, ALBEF	62-78
CAMOUFLAGE 2025 [2]	Text-Text (evidence-based)	Fake News Detection	41-47
Manipulating Multimodal Agents 2025 [25]	Cross-modal (agentic)	GPT-4o, Gemini	70+

in presenza di vincoli realistici (query limitate, vincoli semantici o vincoli di modalità) è possibile compromettere modelli multimodali di ultima generazione, con tassi di successo compresi tra il 40% e il 70%.

2.4 Contromisure e difese

Di fronte alle vulnerabilità emerse, la ricerca ha proposto numerose strategie di difesa per rafforzare i modelli multimodali. Nessuna soluzione è definitiva, ma è possibile distinguerne alcune principali.

2.4.1 Tecniche di robustezza dei modelli

Una prima classe di metodi riguarda il training stesso dei modelli:

- **Adversarial training** - consiste nell'inserire esempi avversari nel processo di addestramento per migliorare la resistenza del modello. Madry et al. [13] dimostrano che, su ImageNet, questa tecnica riduce di oltre il 70% la vulnerabilità a FGSM e PGD rispetto al training standard. Studi successivi ne hanno esteso l'applicazione a modelli vision-language, mostrando incrementi medi di robustezza del 10-15% rispetto a baseline non avversarie [28].
- **Data augmentation multimodale** - l'obiettivo è quello di ampliare la varietà dei dati di addestramento includendo parafrasi testuali, variazioni stilistiche o trasformazioni visive. Nei modelli multimodali, questa tecnica riduce la sensibilità alle variazioni di dominio e migliora la generalizzazione di circa 5-8 punti percentuali su dataset distribuiti in maniera diversa, è una tecnica presente anche in CLIP [18].
- **Ensemble methods** - combinano più modelli o viste differenti dello stesso input, così che un singolo attacco non comprometta l'intero sistema. Tramer et al. [24] mostrano che, nei setting cross-model, l'ensemble training riduce la trasferibilità degli attacchi fino al 40% rispetto ai modelli singoli, rendendo più difficile costruire perturbazioni efficaci.

2.4.2 Trade-off tra accuratezza e robustezza

Un aspetto critico è che la ricerca di robustezza spesso riduce le prestazioni in scenari standard. Ad esempio, Engstrom et al. nel 2019 [6] hanno notato che l'adversarial training può abbassare l'accuratezza sui dati "puliti". Per questo motivo, le difese vengono oggi valutate considerando il trade-off fra accuratezza

e robustezza complessiva, cioè quanto si va a perdere in termini di accuratezza per guadagnare robustezza.

2.4.3 Esempi applicativi e risultati

Nel dominio multimodale, i risultati più recenti mostrano che l'integrazione di strategie difensive mirate produce miglioramenti concreti. Safe-CLIP [17], ad esempio, introduce un filtro di debiasing sui concetti NSFW e sui bias sensibili, ottenendo un aumento del 12% nella robustezza alle perturbazioni testuali e una riduzione del 9% nei falsi positivi durante la classificazione cross-modale. Analogamente, VLAttack [28] riporta che l'adversarial fine-tuning di ALBEF e CLIP riduce il tasso di successo dell'attacco (ASR) dal 78% al 58%, a fronte di un lieve calo (circa 3%) di accuratezza su dati non perturbati.

2.5 Discussione e Posizionamento della Tesi

L'analisi della letteratura mette in luce progressi notevoli, ma anche evidenti lacune, che giustificano direttamente la struttura sperimentale di questa tesi.

2.5.1 Limitazioni e sfide aperte

Nonostante i progressi, la ricerca sugli attacchi avversari multimodali presenta ancora molte sfide. Gli esperimenti in letteratura sono spesso condotti su dataset ristretti e in condizioni controllate, il che rende difficile valutare la reale gravità delle minacce in scenari reali. Inoltre, molte difese sono specifiche per un singolo modello o dominio, risultando difficilmente trasferibili.

Le sfide principali da evidenziare sono:

- **Scalabilità:** le difese devono essere applicabili su larga scala, non solo in laboratorio.
- **Generalizzazione:** un modello robusto contro un certo tipo di attacco dovrebbe esserlo anche per gli altri.
- **Explainability:** comprendere come e perché un sistema è stato ingannato è cruciale per progettare difese migliori.

- **Metriche Standard:** mancano benchmark consolidati e metriche standard per valutare la robustezza cross-modale in modo comparativo.

Le prospettive di ricerca future si concentrano sull'aumento della robustezza e della comprensione dei modelli multimodali. In particolare, la letteratura propone alcune direzioni promettenti:

- **Analisi della vulnerabilità strutturale:** come indicato da Bethany et al. [2], sarà importante indagare la relazione tra le caratteristiche linguistiche dei claim, la distanza dal confine decisionale e il successo dell'attacco, per comprendere meglio quali tipologie di contenuti risultano più manipolabili.
- **Difese basate su moduli di retrieval e comparazione più robusti:** l'integrazione di tecniche di controllo semantico e di semplificazione testuale potrebbe ridurre significativamente il tasso di successo degli attacchi, come mostrato dagli esperimenti di CAMOUFLAGE [2].
- **Espansione dei dati multimodali:** secondo Mura et al. [15], l'inclusione di nuove fonti (come commenti, metadati o dinamiche sociali) può aumentare la capacità dei modelli di cogliere incoerenze più sottili e resistere meglio a manipolazioni avversarie.
- **Adversarial learning dedicato al multimodale:** Abdali et al. [1] sottolineano la necessità di sviluppare architetture multimodali esplicitamente progettate per resistere a perturbazioni cross-modali.

Nel complesso, la ricerca futura dovrà unire approcci di difesa e spiegabilità, promuovendo sistemi multimodali capaci di apprendere da attacchi precedenti e di adattarsi a nuove forme di manipolazione.

2.5.2 Posizionamento della Tesi

Questa analisi dello stato dell'arte conferma i gap di ricerca identificati nell'Introduzione in 1.3. La letteratura esistente, pur essendo ricca, si concentra principalmente su due fronti:

1. Dimostrare che gli attacchi unimodali funzionano [13, 11].

2. Dimostrare che gli attacchi multimodali sono possibili ed efficaci [28, 2].

Tuttavia, manca un'analisi comparativa diretta che risponda alle domande di ricerca centrali di questa tesi: **a parità di contenuto, la fusione delle modalità amplifica o riduce la vulnerabilità rispetto a un attacco unimodale?**

La letteratura tende a esaminare gli attacchi multimodali in modo isolato, senza realmente quantificare il "guadagno" (o la "perdita") di robustezza che la fusione multimodale porta rispetto alla semplice somma delle sue parti unimodali. Non è chiaro, ad esempio, se un modello confuso da un attacco combinato (testo+immagine) lo sarebbe stato altrettanto se avesse affrontato solo la perturbazione testuale o solo quella visiva.

Questo lavoro si inserisce proprio in questo specifico vuoto. Proponendo una metodologia sperimentale per isolare e misurare l'impatto della fusione multimodale sulla robustezza avversaria, questa tesi si propone di quantificare il contributo dell'interazione cross-modale al comportamento finale del modello. Inoltre, il lavoro si impegna a esplorare una dimensione finora poco considerata nella letteratura: la vulnerabilità dei modelli multimodali in scenari a risorse limitate. Dimostrando che è possibile generare perturbazioni efficaci anche con modelli leggeri e hardware modesto, la tesi offre una visione più realistica sulla fattibilità degli attacchi nel mondo reale..

Capitolo 3

Materiali e Metodi

In questo capitolo vengono descritti i materiali, i software e le metodologie sperimentali utilizzate per analizzare la robustezza multimodale del modello preso in esame.

L'obiettivo è illustrare in modo trasparente le scelte tecniche adottate, i vincoli sperimentali incontrati e le motivazioni metodologiche che hanno guidato la configurazione finale della pipeline.

L'intero lavoro è stato svolto in ambiente Python, sfruttando il framework PyTorch per la gestione dei modelli, dei tensori e delle operazioni di calcolo su GPU e CPU. Gli esperimenti sono stati condotti su una macchina locale con risorse computazionali limitate, dotata di una GPU NVIDIA GTX 1050 con 2 GB di VRAM, un processore Intel Core i7 di ottava generazione e 16 GB di RAM unificata. Queste condizioni hanno rappresentato un vincolo rilevante, che hanno portato a privilegiare soluzioni leggere e facilmente eseguibili in locale, pur mantenendo una sufficiente capacità di sperimentazione multimodale.

3.1 Framework e strumenti software

3.1.1 PyTorch e gestione dei modelli

Il framework **PyTorch** [16] ha costituito la base operativa per l'intero progetto, offrendo un'infrastruttura flessibile per la gestione dei tensori, il calcolo automatico dei gradienti e la definizione dinamica dei grafi computazionali. Tutte le componenti principali della pipeline sono state sviluppate utilizzando le funzio-

nalità native di PyTorch. Inoltre, la libreria `torchattacks` è stata impiegata per la realizzazione gli attacchi iterativi sulle immagini.

3.1.2 OpenCLIP e architettura multimodale

Il modello target è **OpenCLIP ViT-B/16**, una variante open-source di CLIP [18] resa disponibile tramite la libreria Hugging Face Transformers [27]. OpenCLIP implementa due encoder indipendenti, uno visivo e uno testuale allineati in uno spazio semantico condiviso. Nello specifico, l'encoder visivo è un Vision Transformer (ViT-B/16) caricato tramite la classe `CLIPVisionModel.from_pretrained`, mentre la componente testuale è basata sul modello **TinyLlama-1.1B-Chat-v1.0**, caricato tramite `AutoModelForCausalLM.from_pretrained`. Per la tokenizzazione e il pre-processing delle immagini sono stati utilizzati, rispettivamente, `AutoTokenizer` e `AutoImageProcessor`.

3.1.3 Ollama e modello linguistico Phi-3:instruct

Per la generazione delle perturbazioni testuali è stato usato il modello **Phi-3:instruct**, eseguito localmente tramite la piattaforma Ollama. Quest'ultima consente l'esecuzione di modelli linguistici in ambienti locali senza dipendere da infrastrutture cloud, gestendo le richieste tramite API HTTP su un server interno alla macchina. In questo modo, la generazione avviene completamente offline, migliorando la privacy dei dati e la replicabilità degli esperimenti.

Phi-3:instruct è stato utilizzato per riscrivere i testi del dataset, generando parafrasi semanticamente coerenti ma linguisticamente variate, con l'obiettivo di introdurre perturbazioni testuali realistiche e potenzialmente ingannevoli per il modello multimodale. In alcune occasioni, tuttavia, il modello ha prodotto risposte anomale, come frammenti di markup o codice, che compromettevano la validità della perturbazione.

Per garantire la qualità dei campioni considerati, è stata quindi condotta una seconda esecuzione in cui le riscritture sono state verificate tramite la **Text Similarity**, includendo solo i testi con similarità maggiore o uguale a 0.5, così da preservare la coerenza semantica e l'affidabilità dei risultati finali.

3.2 Motivazioni metodologiche

La scelta degli strumenti e delle metodologie adottate è stata influenzata in gran parte da valutazioni di efficienza, scalabilità e adattabilità a causa del contesto computazionalmente limitato.

PyTorch è stato scelto per la sua ampia diffusione nella ricerca accademica, la compatibilità con librerie di attacco come `torchattacks` e la possibilità di personalizzare facilmente le funzioni di perdita e i flussi di ottimizzazione. La sua natura a grafo dinamico ha inoltre facilitato l'integrazione con modelli multimodali e processi iterativi di perturbazione.

La scelta di OpenCLIP ViT-B/16 è motivata dal suo equilibrio tra prestazioni e accessibilità: rappresenta uno standard de facto per la valutazione dei modelli vision-language, garantendo compatibilità con numerosi dataset e supporto da parte della comunità open-source. La combinazione con TinyLlama come encoder testuale ha permesso di mantenere la pipeline leggera e completamente eseguibile in CPU, pur conservando capacità semantiche sufficienti per il task di verifica multimodale. Questa configurazione è quella standard che Mura et al. hanno definito per la valutazione del loro modello di fake news detection [15]

Nel caso delle perturbazioni visive, dopo una fase di confronto con diversi metodi implementati in `torchattacks` (tra cui FGSM, OnePixel e DeepFool), è stato scelto il Projected Gradient Descent (PGD) [13]. Tale metodo si è dimostrato il più adatto a bilanciare l'impercettibilità della perturbazione con l'efficacia dell'attacco, offrendo un controllo preciso sui parametri d'intensità e sul numero di iterazioni. Gli altri metodi esplorati producevano alterazioni visivamente identificabili; DeepFool, seppur utile per valutare la distanza decisionale, risultava meno flessibile e più oneroso dal punto di vista computazionale.

Per la perturbazione testuale, l'approccio si ispira al framework CAMOUFLAGE [2], che utilizza modelli di grandi dimensioni come GPT-4 per generare riscritture avversarie. Nel presente studio, tuttavia, si è optato per il modello Phi-3:instruct in virtù della sua leggerezza (circa 2 GB) e dell'esecuzione locale tramite Ollama, che consente un'attività di parafrasi anche in assenza di GPU dedicate. Tale scelta evidenzia inoltre come sia possibile condurre analisi di robustezza multimodale anche con risorse computazionali minime, dimostrando che l'attacco ai modelli di allineamento testo-immagine può essere realizzato a basso costo e con strumenti accessibili.

Nel complesso, le scelte metodologiche adottate rispondono a una duplice esigenza: da un lato, garantire un’analisi rigorosa e riproducibile della robustezza multimodale; dall’altro, mostrare come anche un’infrastruttura limitata possa supportare un approccio di ricerca completo e tecnicamente solido.

3.3 Dataset e pre-processing

Il dataset utilizzato per la sperimentazione è **ReCOVery** [30], lo stesso impiegato nel lavoro *Is it fake or not?* [15] per il fine-tuning del modello di fake-news detection Themis [29].

ReCOVery è un benchmark ampiamente usato per la classificazione di notizie affidabili e non affidabili, composto da 2029 articoli, di cui 843 per il training, 283 per la validazione e 283 per il test. In questo lavoro è stato utilizzato esclusivamente il test set, in modo da evitare fenomeni di overfitting e simulare uno scenario realistico di attacco su campioni non visti in fase di addestramento.

Le immagini sono state preprocessate tramite il processor ufficiale di OpenCLIP, con ridimensionamento a 224×224 pixel, normalizzazione rispetto ai valori di ImageNet e conversione in tensori float32.

I testi sono stati tokenizzati con il tokenizer di TinyLlama, rimuovendo caratteri speciali e applicando padding o troncamento fino a un massimo di 128 token. Tale limite è stato fissato per contenere l’impatto computazionale della pipeline e garantire la compatibilità con le risorse hardware disponibili, senza compromettere in modo significativo la qualità semantica dei testi analizzati. La tokenizzazione ha seguito lo stesso approccio proposto in *Is it fake or not?* [15]

Il dataset alternativo Fakeddit, sebbene più ampio, è stato escluso per motivi di scalabilità, in quanto avrebbe richiesto un carico computazionale non compatibile con le risorse disponibili.

3.4 Perturbazioni delle immagini

Come accennato in precedenza, le perturbazioni visive sono state generate utilizzando l’attacco **Projected Gradient Descent (PGD)** [13], una delle tecniche più diffuse per la valutazione della robustezza dei modelli di deep learning in scenari white-box. L’algoritmo esegue un processo iterativo di aggiornamento

dell'immagine di input lungo la direzione del gradiente della funzione di perdita, proiettando a ogni passo la perturbazione risultante all'interno di una palla L_∞ di raggio ϵ , così da mantenere il vincolo di impercettibilità.

Formalmente, ad ogni iterazione t , l'immagine perturbata x_t viene aggiornata secondo la regola:

$$x_{t+1} = \Pi_{B_\epsilon(x)} (x_t + \alpha \cdot \text{sign}(\nabla_x \mathcal{L}(f_\theta(x_t), y)))$$

dove $\Pi_{B_\epsilon(x)}$ denota l'operatore di proiezione nel dominio consentito, α è il passo di aggiornamento, $\mathcal{L}$ la funzione di perdita e f_θ il modello target parametrizzato dai pesi θ .

Dopo una serie di esperimenti preliminari, sono stati selezionati i seguenti set di iperparametri per l'esecuzione dell'algoritmo PGD:

- 20 iterazioni, $\epsilon = \frac{4}{255}$, con una similarità media $SSIM = 0.96$;
- 25 iterazioni, $\epsilon = \frac{3}{255}$, con una similarità media $SSIM = 0.98$;
- 30 iterazioni, $\epsilon = \frac{2}{255}$, con una similarità media $SSIM = 0.99$.

La configurazione finale adottata, 25 iterazioni e $\epsilon = \frac{3}{255}$, rappresenta un buon compromesso tra efficacia dell'attacco e qualità percettiva. Il valore dello step di aggiornamento è stato definito empiricamente come:

$$\alpha = \frac{\epsilon}{n \cdot \text{args.alpha_factor}}$$

dove n indica il numero di iterazioni e `alpha_factor` un fattore moltiplicativo fissato a 2.0.

La qualità delle perturbazioni è stata valutata mediante la **Structural Similarity Index Measure (SSIM)**, implementata tramite la classe `StructuralSimilarityIndexMeasure` della libreria `torchmetrics.image`. L'obiettivo è stato mantenere un valore medio di SSIM superiore a 0.95, cercando di mantenere le perturbazioni il più impercettibili all'occhio umano possibile pur essendo sufficientemente incisive da modificare la predizione del modello. Il processo è stato applicato solo ai campioni che il modello classificava correttamente in input pulito, così da misurare l'effettiva vulnerabilità indotta dalla perturbazione.

Infine, per ogni immagine perturbata, sono stati salvati sia il valore numerico di SSIM sia l'output del modello, così da consentire l'analisi incrociata con le perturbazioni testuali e multimodali discusse nelle sezioni successive.

3.5 Perturbazioni testuali e prompt engineering

Le perturbazioni testuali sono state generate tramite Phi-3:instruct utilizzando un prompt ispirato al framework CAMOUFLAGE [2], semplificato per adattarsi alla capacità del modello. Il prompt finale adottato è il seguente:

Prompt per la perturbazione

You are an expert text editor. Your task is to rewrite a news article in plain English. Make only small and natural changes, such as replacing a few words with synonyms or slightly rephrasing sentences. Keep the same overall meaning, facts, and tone of the original. Ensure the rewritten text stays very close in meaning to the original - at least 85% semantically similar. Do not add or remove information, and do not explain your edits. Write only the rewritten news text, nothing else.

Example:

Original: Donald Trump publicly criticized the Pope during his speech on foreign policy.

Rewritten: The U.S. president publicly criticized the Pope during a foreign policy address.

Now rewrite the following news text:

Il prompt è stato ottimizzato attraverso un processo iterativo di prompt engineering, utilizzando ChatGPT e Gemini. Durante questo processo, le riscritture ottenute sono state confrontate con quelle desiderate, affinando le istruzioni passo dopo passo. Grazie a questa procedura, è stato possibile creare testi parafrasati che mantenessero il significato originale, introducendo però abbastanza variazioni da influenzare la decisione del modello multimodale.

3.6 Metriche di valutazione

Per valutare in modo rigoroso l'effetto delle perturbazioni unimodali e multimodali sono state adottate metriche classiche della classificazione insieme a misure specifiche per la robustezza avversaria e la preservazione percettiva/semantica. Di seguito vengono elencate, spiegate e formalizzate le metriche principali impiegate nel lavoro.

- **Accuracy:** Misura la frazione di istanze correttamente classificate sul totale. È una metrica standard della classificazione [21].

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}_i = y_i)$$

dove $\hat{y}_i$ è la predizione del modello sul campione i e y_i è la sua etichetta reale.

- **Adversarial Accuracy (ADV accuracy):** L'accuratezza calcolata sulle istanze dopo l'applicazione della perturbazione avversaria.

$$\text{ADV Accuracy} = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}_i^{\text{adv}} = y_i)$$

Questa metrica è comunemente usata negli studi di robustezza avversaria (cfr. Madry et al. [13]).

- **Δ Accuracy:** Differenza tra l'accuratezza sui dati puliti e l'accuratezza sui dati perturbati; quantifica la perdita di performance dovuta all'attacco.

$$\Delta \text{Accuracy} = \text{Accuracy}_{\text{clean}} - \text{Accuracy}_{\text{adv}}$$

Questa è una definizione pratica e frequentemente impiegata per riassumere l'impatto dell'attacco.

- **Flip Rate (FR):** Percentuale di esempi la cui predizione varia dopo la perturbazione, indipendentemente dalla correttezza rispetto alla label. In letteratura esistono versioni aggregate (es. mean Flip Rate su perturbazioni temporali/di dominio); metriche analoghe sono state adottate nei benchmark

su perturbazioni naturali (ImageNet-P / mFR) [10].

$$\text{Flip Rate} = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}_i^{\text{clean}} \neq \hat{y}_i^{\text{adv}})$$

- **Attack Success Rate (ASR).** Percentuale di esempi che erano correttamente classificati in condizione *clean* e che diventano erroneamente classificati dopo l'attacco. La ASR è la metrica principale per quantificare l'efficacia di un attacco (ampiamente usata in letteratura recente sugli attacchi multimodali e pipeline di misinformation detection, vedi ad esempio CAMOUFLAGE [2] e VLAttack [28]).

$$\text{ASR} = \frac{|\{i : \hat{y}_i^{\text{clean}} = y_i \wedge \hat{y}_i^{\text{adv}} \neq y_i\}|}{|\{i : \hat{y}_i^{\text{clean}} = y_i\}|}$$

Questa è la definizione che è stata usata nel codice sperimentale (vedi la funzione `compute_robustness_metrics`).

È importante distinguere l'Attack Success Rate dal Flip Rate. Mentre l'ASR misura quanti campioni, originariamente classificati correttamente, vengono indotti a una classificazione errata a seguito dell'attacco, il FR misura semplicemente la percentuale di campioni per cui la predizione avversaria è diversa da quella originale (pulita). In sintesi, il FR non tiene conto dell'etichetta reale (y_i): conta qualsiasi "cambio di idea" del modello, anche se questo dovesse passare da una predizione errata a un'altra (o addirittura a quella corretta). L'ASR, invece, è una metrica di successo più rigorosa, in quanto si focalizza esclusivamente sulla transizione da *corretto* $\rightarrow$ *errato*.

- **Structural Similarity Index Measure (SSIM):** Misura della similarità percettiva tra immagine originale e immagine perturbata; considera luminosità, contrasto e struttura locali. SSIM è una misura standard nell'analisi della qualità dell'immagine ed è formalizzata in [26]. La forma semplificata (per patch locali) è:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

dove μ_x, μ_y sono le medie locali, σ_x^2, σ_y^2 le varianze locali e σ_{xy} la cova-

rianza locale; C_1, C_2 sono costanti di stabilizzazione. Nel presente lavoro è stato utilizzata l'implementazione `StructuralSimilarityIndexMeasure` della libreria `torchmetrics.image` (equivalente alla definizione classica di Wang et al. [26]).

- **Cosine Similarity sugli embedding testuali (Text Similarity).** Per valutare quanto il testo riscritto rimanga semanticamente vicino al testo originale, è stato utilizzato un embedding di frasi (Sentence-BERT / all-MiniLM-L6-v2) e la similarità coseno fra i vettori:

$$\text{CosSim}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2}$$

L'approccio di misurare la similarità semantica tramite coseno su sentence-embeddings è ampiamente utilizzato nella letteratura moderna sul semantic textual similarity e nei lavori su perturbazioni testuali; un riferimento metodologico per l'uso di sentence-embeddings e coseno è Reimers & Gurevych [19]. Nel codice sperimentale è stata usata la rete all-MiniLM-L6-v2 e la funzione `util.cos_sim` della libreria `sentence-transformers`.

Alcune di queste misure (Accuracy, ASR, SSIM, Cosine Similarity) sono standard e ampiamente riportate in letteratura; altre, come Δ Accuracy o Flip Rate, sono concetti pragmatici adottati frequentemente nei benchmark di robustezza (ad esempio, ImageNet-P introduce aggregati basati su Flip Rate) e nella pratica sperimentale sono formalizzate come sopra per garantire riproducibilità [10].

Dove non esiste una precisa fonte canonica, sono state scelte definizioni semplici, interpretabili e coerenti.

3.7 Setup sperimentale e riproducibilità

L'ambiente di sviluppo è stato configurato mediante un ambiente virtuale Python standard, al fine di mantenere una struttura leggera e facilmente portabile. Le principali dipendenze includono PyTorch e Transformers di Hugging Face. Per garantire coerenza tra diverse esecuzioni, sono stati fissati i semi randomici di PyTorch e NumPy. È stato necessario fissare le versioni delle varie librerie e di Python stesso a causa di incompatibilità con il modello utilizzato nelle nuove

versioni. In ogni caso le versioni che sono state utilizzate per questi esperimenti sono specificate nella repository GitHub.

La riproducibilità dei risultati dipende in modo sostanziale dalla disponibilità dei pesi del modello Themis, poiché l’approccio adottato è di tipo white-box, ossia presuppone l’accesso diretto ai gradienti e ai parametri del modello target.

Tuttavia, la struttura modulare della pipeline rende possibile l’adattamento a modelli diversi, purché si disponga di interfacce compatibili per la forward pass e per la gestione di token testuali e immagini preprocessate.

Sebbene la pipeline sia stata sviluppata e testata in condizioni di risorse hardware limitate (CPU Intel i7 di ottava generazione, GPU NVIDIA GTX 1050 con 2 GB di memoria dedicata e 16 GB di RAM) essa si è dimostrata sufficientemente stabile e generalizzabile per condurre un’analisi sistematica della robustezza multimodale del modello in questione. Questo dimostra come anche configurazioni computazionalmente modeste possano essere efficaci nello studio sperimentale di modelli multimodali complessi, a patto di un’attenta ottimizzazione dei parametri e dell’uso della memoria.

Capitolo 4

Esperimenti e Risultati

In questo capitolo vengono presentati gli esperimenti condotti per analizzare la robustezza del modello multimodale adottato nei confronti di perturbazioni avversarie, applicate singolarmente su testo e immagine e congiuntamente su entrambe le modalità.

L'obiettivo principale è valutare in che misura il comportamento del modello venga alterato da perturbazioni minime, realistiche e semanticamente coerenti.

4.1 Impostazione generale degli esperimenti

Gli esperimenti sono stati condotti in un contesto white-box, poiché erano disponibili sia la struttura architeturale del modello che i suoi pesi pre-addestrati. Questo ha reso possibile calcolare i gradienti e applicare direttamente l'attacco PGD sulle rappresentazioni visive.

Tuttavia, la pipeline proposta può essere facilmente adattata anche a scenari black-box, in cui l'accesso ai pesi non è consentito ma si possono effettuare query al modello target. In tale contesto emergono nuove sfide, come la definizione di un limite massimo di query o la necessità di stimare il gradiente in modo approssimato, aspetti discussi ad esempio nel lavoro CAMOUFLAGE [2].

Nel presente studio, l'esperimento si è concentrato sul caso white-box per analizzare in profondità il comportamento interno del modello e isolare gli effetti specifici delle perturbazioni, lasciando le estensioni black-box come possibile sviluppo futuro.

4.2 Pipeline sperimentale

La procedura di test è stata organizzata in più fasi sequenziali:

1. Predizione sui dati puliti per identificare i campioni correttamente classificati;
2. Applicazione della perturbazione testuale (`text_corruption`) mediante LLM;
3. Applicazione della perturbazione visiva (`img_corruption`) tramite attacco PGD;
4. Generazione della versione multimodale (`multimodal_corruption`);
5. Calcolo delle metriche di performance e robustezza per ciascuno scenario.

Sono state quindi valutate quattro configurazioni per ogni campione (immagine, testo):

- **Clean:** immagine e testo originali;
- **Text corruption:** testo riscritto, immagine originale;
- **Image corruption:** immagine perturbata, testo originale;
- **Multimodal corruption:** entrambe le modalità perturbate.

Le perturbazioni sono state applicate solo sui campioni che il modello già classificava correttamente nella condizione pulita, così da garantire che gli errori osservati fossero esclusivamente indotti dagli attacchi e in modo da sfruttare gli errori naturali del modello.

Ogni esperimento ha richiesto in media circa 15 ore di esecuzione, a causa dell'elevato numero di predizioni e della limitata capacità computazionale disponibile.

La struttura logica dell'intero processo è sintetizzata in Figura 4.1, che illustra il flusso operativo della pipeline sperimentale: dal caricamento dei modelli e dei dati, fino alla generazione delle perturbazioni e al calcolo delle metriche di robustezza. Il codice è disponibile alla seguente repository GitHub




Figura 4.1: Pipeline sperimentale. Schema ad alto livello della procedura di valutazione della robustezza multimodale: il sistema esegue le predizioni sui dati puliti, genera perturbazioni testuali e visive, costruisce le versioni multimodali corrotte e calcola infine le metriche di performance e robustezza per ciascuno scenario.

4.3 Parametri di attacco

4.3.1 Perturbazioni visive

Come detto in precedenza, le perturbazioni sulle immagini sono state realizzate mediante il metodo Projected Gradient Descent (PGD) [13] e, dopo una fase di

tuning empirico, la configurazione ottimale è risultata:

$$\epsilon = 2/255, \quad n_{\text{iter}} = 30,$$

con uno step α calcolato dinamicamente come:

$$\alpha = \frac{\epsilon}{n_{\text{iter}} \cdot \text{alpha_factor}}.$$

Questa configurazione ha offerto un buon equilibrio tra intensità della perturbazione e impercettibilità visiva, con valori medi di SSIM superiori a 0.95.

4.3.2 Perturbazioni testuali

Per quanto riguarda Phi-3:instruct, eseguito localmente tramite la piattaforma Ollama, ogni riscrittura è stata ottenuta fornendo in input il testo originale della notizia, insieme al prompt in 3.5 (LLM_CORRUPTER_PROMPT) il quale prende ispirazione dall'approccio di CAMOUFLAGE [2].

L'interazione con Ollama è avvenuta tramite il seguente schema operativo:

```
user_content = f"News article:\n{news['txt']}"
response = ollama.chat(
    model="phi3:instruct",
    options={"temperature": 0.3},
    messages=[
        {"role": "system", "content": LLM_CORRUPTER_PROMPT},
        {"role": "user", "content": user_content},
    ],
)
corr_txt = response["message"]["content"].strip()
corr_news = {"txt": corr_txt, "img": news["img"]}
```

Il valore di `temperature` è stato impostato a 0.3 per ridurre la casualità nella generazione e mantenere alta la consistenza semantica tra testo originale e testo riscritto. Temperature più elevate (per esempio 0.7-1.0) avrebbero potuto introdurre variazioni eccessive o deviazioni di significato, mentre valori troppo bassi (per esempio 0.0-0.2) avrebbero potuto produrre riscritture quasi identiche. Il

valore 0.3 ha quindi rappresentato un compromesso efficace, in grado di garantire diversità lessicale minima ma sufficiente per generare una vera perturbazione avversaria, preservando al contempo la plausibilità del contenuto.

Per garantire la coerenza tra il testo originale e quello riscritto, è stata calcolata la similarità semantica tra il testo originale e quello corrotto mediante la text similarity sugli embedding ottenuti dal modello all-MiniLM-L6-v2 della libreria SentenceTransformers:

```
txt_similarity = util.cos_sim(
    model_sbert.encode(news["txt"], convert_to_tensor=True),
    model_sbert.encode(corr_txt, convert_to_tensor=True)
).item()
```

Infine, i testi sono stati tokenizzati tramite il tokenizer di TinyLlama, con padding o troncamento a 128 token per motivi di compatibilità computazionale.

4.4 Risultati quantitativi

4.4.1 Metriche di classificazione

Nella Tabella 4.1 sono riportate le metriche classiche di classificazione (accuracy, precision, recall, F1 e macro-F1) nello scenario pulito e nei tre di perturbazione. Dalla tabella si evince una chiara tendenza: la degradazione delle prestazioni è

Tabella 4.1: *Metriche di classificazione nei diversi scenari.*

Scenario	Accuracy	Precision	Recall	F1	Macro-F1
Clean	0.908	0.987	0.905	0.944	0.842
Text corruption	0.834	0.877	0.938	0.907	0.58
Image corruption	0.145	0.571	0.016	0.032	0.133
Multimodal corruption	0.032	0.14	0.025	0.042	0.032

minima per le perturbazioni testuali, ma drammatica per quelle visive e, ancor di più, per quelle multimodali. In particolare, la combinazione di perturbazioni coordinate porta l'accuratezza al di sotto del 5%, indicando un forte effetto combinato negativo tra le due modalità.

4.4.2 Metriche di robustezza

La Tabella 4.2 riporta le metriche specifiche di robustezza definite in 3.6. L'ASR

Tabella 4.2: *Metriche di robustezza per le tre tipologie di perturbazione.*

Metrica	Text Corr.	Image Corr.	Multimodal Corr.
ADV Accuracy	0.834	0.145	0.032
Δ Accuracy	0.074	0.763	0.876
Flip Rate	0.145	0.806	0.926
ASR	0.121	0.864	0.992

multimodale raggiunge un valore pari a 0.992, indicando che oltre il 99% delle predizioni corrette sui dati puliti viene invertito quando entrambe le modalità sono perturbate.

Rispetto all'attacco testuale isolato (ASR = 0.121), si osserva un incremento di circa il **+720%**, mentre rispetto all'attacco visivo (ASR = 0.864) l'aumento è di circa il **+12.8%**.

Questo risultato conferma che la vulnerabilità del modello non è il semplice risultato di due effetti additivi, ma emerge da una **interazione non lineare e sinergica** tra le rappresentazioni testuali e visive, capace di amplificare in modo drastico gli errori di classificazione quando le perturbazioni vengono coordinate.

4.5 Analisi qualitativa

Le matrici di confusione, riportate in Figura 4.2, mostrano la distribuzione degli errori nei diversi scenari. Nel caso multimodale si osserva un netto peggioramento della diagonale principale, a conferma della perdita quasi totale di coerenza nelle predizioni.

4.6 Esempi qualitativi

In questa sezione vengono riportati alcuni esempi rappresentativi che illustrano l'effetto delle perturbazioni testuali e visive sulle predizioni del modello. Ogni esempio è tratto direttamente dai risultati sperimentali salvati in formato `.json`, e include i valori numerici delle metriche di similarità, le predizioni del modello nei vari scenari e un estratto dei testi originali e corrotti.




Figura 4.2: Confronto tra le matrici di confusione nei quattro scenari di valutazione: *clean*, *text corruption*, *image corruption* e *multimodal corruption*.

4.6.1 Struttura dei risultati

Ogni file `.json` contiene le seguenti chiavi:

- `index`: identificativo univoco del campione nel test set;
- `true_label`: etichetta reale (0 = notizia falsa, 1 = notizia vera);
- `pred_clean`: predizione del modello sull'input pulito;
- `pred_img_corr`, `pred_txt_corr`, `pred_multimodal_corr`: predizioni rispettivamente con immagine corrotta, testo corrotto e perturbazione multimodale;

- SSIM: similarità strutturale tra immagine originale e immagine perturbata (0-1);
- txt_similarity: similarità coseno tra embedding del testo originale e riscritto (0-1);
- original_txt, corr_txt: testo originale e testo riscritto.

Nei casi riportati, si osserva che anche perturbazioni quasi impercettibili possono determinare un'inversione della predizione del modello, evidenziando la vulnerabilità cross-modale.

4.6.2 Esempi positivi

I seguenti esempi qualitativi mostrano casi in cui il modello prediceva correttamente l'input pulito, ma cambia classificazione quando le due modalità vengono perturbate simultaneamente. Inoltre, la differenza tra il testo originale e quello perturbato è evidenziata utilizzando una codifica a colori per mostrare chiaramente l'intervento dell'attacco avversario. Per semplicità di lettura, i testi sono mostrati in forma abbreviata. Questi estratti, sebbene concisi, permettono di apprezzare la flessibilità dell'LLM adoperato, capace sia di effettuare piccole sostituzioni lessicali (come nel Sample 21), sia di generare parafrasi più estese che cambiano la struttura delle frasi (come nel Sample 175), pur mantenendo la coerenza semantica. L'analisi completa e i testi integrali utilizzati per gli esperimenti sono disponibili nella repository GitHub del progetto.

Per ogni esempio visivo sono presenti tre immagini: l'immagine originale, l'immagine perturbata tramite PGD e l'immagine differenza tra l'immagine originale e quella perturbata. Poiché le perturbazioni introdotte da PGD sono progettate per essere quasi impercettibili, l'immagine differenza è risultata essere completamente nera (apparentemente). Per evidenziare al meglio gli effetti della perturbazione, la differenza è stata amplificata di 15 volte tramite un fattore moltiplicativo, rendendo più visibili le aree specifiche in cui l'attacco ha agito.

Sample 21

Indice: 21

Figura: 4.3

Etichetta reale: 0 (notizia falsa)

Predizioni: clean = 0, img_corr = 0, txt_corr = 0, multimodal_corr = 1

SSIM: 0.979 **Text similarity:** 0.858

Estratto testo originale

Israels **intent** to annex **part** of West Bank may **spark new widescale Middle East crisis amidst global pandemic...**

Estratto testo riscritto

Israels **plan** to annex **parts** of **the** West Bank may **trigger another widespread crisis in the Middle East during the global pandemic...**

Questo esempio mostra come una riscrittura semanticamente simile (similarità 0.858) e un'alterazione visiva quasi impercettibile (SSIM 0.979) possano combinarsi per invertire la decisione del modello, portando da notizia falsa a notizia vera. La vulnerabilità emerge dunque dall'interazione tra linguaggio e visione, non da una singola modalità.

Sample 167

Indice: 167

Figura: 4.4

Etichetta reale: 0 (notizia falsa)

Predizioni: clean = 0, img_corr = 0, txt_corr = 0, multimodal_corr = 1

SSIM: 0.959 **Text similarity:** 0.943

Estratto testo originale

Putin **considers using Armed Forces to combat Covid19** Putin considers using Armed Forces to combat Covid19
Yesterday President Vladimir Putin admitted that it could be possible to use opportunities and reserves of the Ministry of Defense **in the fight against the spread of coronavirus in Russia** Representatives of the ministry said however that they estimate the situation with the coronavirus infection in the armed forces as unstable...

Estratto testo riscritto

President Putin has expressed that he is contemplating utilizing resources within the Ministry of Defense, including reserves, as part of Russia's strategy against COVID-19. Representatives from the ministry have conveyed their viewpoint stating they perceive the situation with coronavirus infections among military personnel to be unpredictable...

In questo esempio, è interessante notare l'alta similarità sia della perturbazione visiva che di quella testuale. La combinazione di due perturbazioni molto piccole ha comunque permesso di classificare una fake news come vera.

Sample 175

Indice: 175

Figura: 4.5

Etichetta reale: 0 (notizia falsa)

Predizioni: clean = 0, img_corr = 0, txt_corr = 0, multimodal_corr = 1

SSIM: 0.985 **Text similarity:** 0.846

Estratto testo originale

Not every child is born with skills to solve math equations and divide and multiply swiftly. Most of them struggle with calculations, algebra, and graphs. And the approach most parents take in pushing them toward ability is through destructive feedback. [...] In a time like this, the best thing you can do is take it upon yourself to give your child the math education they truly need...

Estratto testo riscritto

During lockdowns due to COVID-19, many parents might be concerned about their children's math skills. While teachers do their best with online lessons, engagement is often lower. [...] It becomes crucial for parents to provide real-life examples-baking, shopping, or playing games-to make math fun and practical...

Sample 55

Indice: 55

Figura: 4.6

Etichetta reale: 1 (notizia vera)

Predizioni: clean = 1, img_corr = 1, txt_corr = 1, multimodal_corr = 0

SSIM: 0.994 **Text similarity:** 0.92

Estratto testo originale

Dr Ali who runs the Private Harley Street Clinic in London said he was unrepentant about his trading after taking orders for nearly 7000 tests at 375 each [...] What Dr Ali is offering for that 375 takes some explanation [...] Yet it has sold the testing kits for more than three times the 120 that the manufacturer Randox Laboratories in Northern Ireland charges the public directly...

Estratto testo riscritto

Mark Ali, who runs his own private Harley Street Clinic in London, began offering screening kits for three times the price they cost directly to manufacturers like Randox Laboratories after initially being unable to secure enough supplies through government channels...

È importante sottolineare che questo sample è stato preso tra quelli della sperimentazione senza il controllo della text similarity, pertanto la sua riscrittura, sebbene generata dalla stessa pipeline, potrebbe non rispettare i canoni considerati invece nella sperimentazione finale. È stato comunque incluso per il suo elevato valore illustrativo, in quanto dimostra perfettamente la capacità dell'attacco multimodale di indurre un'inversione *True* $\rightarrow$ *False* (censura di notizie vere).

4.6.3 Limitazioni

Nonostante la coerenza generale delle riscritture, il modello *Phi-3:instruct* ha occasionalmente generato testi anomali o con allucinazioni, contenenti markup o sequenze non linguistiche. Un esempio è riportato di seguito:

Sample 144

Esempio di allucinazione testuale

```
You are given that. The FDA's work, and I apologize to a)
\n-3/ \n\nAssistant:*! \n\nTitle \n\n### Solution: In
the documentary filmography(s in anaemia. It seems like this is
your design of all things considered_you canyou \n\nChatbot:
I'deas and then, but notions for each other\u2019t to help me as
a French-Bayesianusually \n\nI/b \n\n# \n\nYou are two years
ago. The
```

In questi casi, la perturbazione è stata esclusa dal set finale poiché non rispettava i vincoli di plausibilità semantica. Tuttavia, la presenza sporadica di tali fenomeni indica i limiti dei modelli leggeri come Phi-3:instruct nel mantenere la coerenza sotto vincoli di temperatura ridotta (0.3) e prompt con task relativamente complessi.

Un'ulteriore limitazione emersa riguarda il funzionamento complessivo della pipeline. In una minoranza di casi, anche quando la perturbazione generata era formalmente valida, il modello multimodale manteneva invariata la predizione. Questo comportamento suggerisce che, pur essendo tecnicamente corrette, alcune perturbazioni non erano sufficientemente incisive da spostare la rappresentazione interna oltre il confine decisionale. Tali situazioni rappresentano un fallimento parziale della pipeline di attacco, che evidenzia la necessità di strategie più accurate nella selezione o intensificazione delle perturbazioni.

È plausibile che, con un maggiore budget computazionale e l'impiego di modelli linguistici più potenti, sia possibile ottenere riscritture più stabili e perturbazioni meglio ottimizzate, riducendo ulteriormente i casi di fallimento e migliorando il funzionamento complessivo della pipeline.

4.7 Discussione dei risultati

L'analisi dei risultati, sia quantitativi che qualitativi, mette in luce aspetti fondamentali sulla solidità del modello multimodale. Si evidenzia come la vulnerabilità non derivi da debolezze isolate, ma piuttosto da un'interazione non lineare tra le due modalità.

In effetti, si delinea un quadro complesso in cui testo e immagine non contribuiscono in modo uniforme al fallimento del modello; al contrario, interagiscono in modo sinergico, amplificando l'impatto delle perturbazioni coordinate.

4.7.1 L'asimmetria della vulnerabilità: dominanza dell'attacco visivo

Il dato più evidente emerso dalle Tabelle 4.1 e 4.2 è la forte asimmetria tra la vulnerabilità testuale e quella visiva.

Da un lato, il modello mostra una buona robustezza semantica alle perturbazioni testuali. Con un ASR (Attack Success Rate) di poco sopra il 10% e una diminuzione di accuratezza di circa **7.4 punti**, le riscritture generate da **Phi-3:instruct**, pur introducendo variazioni linguistiche, non riescono da sole a ingannare il modello. Questo comportamento suggerisce che il sistema mantiene una rappresentazione semantica stabile e coerente, in grado di riconoscere il contenuto fondamentale di una notizia anche se parafrasato.

Dall'altro lato, la fragilità del modello alle perturbazioni visive è estremamente marcata. L'attacco PGD, pur operando con un $\epsilon = 2/255$ e mantenendo una SSIM media superiore a 0.95, provoca un peggioramento quasi totale delle prestazioni: l'accuratezza crolla a **0.145** e l'ASR raggiunge l'**86.4%**.

Questa differenza suggerisce un fenomeno di affidamento maggiore alla parte visiva: il modello sembra attribuire un peso eccessivo alle rappresentazioni dell'immagine rispetto a quelle testuali. In un contesto white-box, i gradienti calcolati dall'attacco PGD riescono infatti a sfruttare in modo molto efficace le vulnerabilità interne del visual encoder e dei primi stadi della fusione multimodale, rendendo la componente visiva il vero punto debole del sistema. L'effetto della perturbazione visiva in un contesto totalmente black-box non è scontato, pertanto è stato lasciato come sviluppo futuro.

4.7.2 Oltre l'additività: l'effetto catalitico dell'attacco multimodale

L'attacco multimodale rappresenta il punto cruciale dell'analisi, poiché rivela una vulnerabilità sinergica che va oltre la semplice somma degli effetti unimodali.

Quando testo e immagine vengono perturbati simultaneamente, l'ASR raggiunge il **99.2%**, indicando che quasi tutte le predizioni corrette sui dati puliti vengono invertite. Rispetto all'attacco testuale ($ASR = 0.121$) si osserva un incremento di circa il **+720%**, mentre rispetto all'attacco visivo ($ASR = 0.864$) l'aumento è di circa il **+12.8%**.

Questo incremento non è spiegabile in termini additivi: la vulnerabilità multimodale deriva da un effetto catalitico.

L'attacco PGD sull'immagine spinge la rappresentazione del modello in una zona di incertezza vicina al confine decisionale. Anche se la perturbazione testuale è minima e semanticamente coerente, funge da innesco che spinge la rappresentazione oltre il limite, cambiando così la classificazione. Questo ci porta a capire che il punto debole non è solo nei singoli encoder, ma nel meccanismo di fusione multimodale, che fatica a gestire rumori deboli ma coordinati tra le due modalità.

4.7.3 Implicazioni qualitative: la minaccia della doppia inversione

L'analisi qualitativa conferma l'impatto pratico e potenzialmente pericoloso di tali vulnerabilità. Gli esempi riportati mostrano non solo una riduzione di precisione ed accuratezza, ma vere e proprie inversioni di classificazione.

Gli attacchi si sono dimostrati efficaci in entrambe le direzioni:

- **Validazione di notizie false** ($False \rightarrow True$): esempi come il 21, il 167 e 175 mostrano casi in cui notizie false vengono classificate come vere dopo la perturbazione multimodale.
- **Censura di notizie vere** ($True \rightarrow False$): come nel campione 55, una notizia reale viene classificata come falsa, simulando un attacco di discredito informativo.

In entrambi i casi, le perturbazioni restano impercettibili ($SSIM = 0.994$ e $Text\ Similarity = 0.92$), rendendo questi attacchi estremamente insidiosi, poiché difficili da rilevare ma con effetti semantici profondi.

4.7.4 Considerazioni sulla metodologia

È importante sottolineare che tali risultati sono stati ottenuti con risorse computazionali limitate e con strumenti open-source. L'uso combinato di un attacco PGD e di un modello linguistico leggero come Phi-3:instruct, eseguito localmente tramite Ollama, dimostra che queste vulnerabilità non sono solo teoriche, ma concretamente riproducibili anche in contesti a bassa potenza di calcolo.

Le rare allucinazioni linguistiche osservate non compromettono la validità dei risultati, poiché i testi incoerenti sono stati esclusi tramite controllo di similarità semantica. Questo passaggio di filtraggio si è rivelato essenziale per evitare errori nella pipeline e mantenere l'affidabilità statistica delle analisi.

Nel complesso, i risultati ottenuti confermano la necessità di sviluppare strategie di difesa che operino a livello cross-modale, poiché un semplice irrobustimento dei singoli encoder non sarebbe sufficiente.

Addestrare i modelli a riconoscere e ignorare discrepanze sottili ma coordinate tra testo e immagine rappresenta la direzione più promettente per migliorare la robustezza multimodale.



(a) *Immagine originale*




(b) *Immagine perturbata ($SSIM = 0.979$)*



(c) *Differenza amplificata $\times 15$*

Figura 4.3: *Esempio di campione #21 - inversione di predizione multimodale False $\rightarrow$ True.*




(a) *Immagine originale*

(b) *Immagine perturbata (SSIM = 0.959)*




(c) *Differenza amplificata $\times 15$*

Figura 4.4: *Esempio di campione #167 - vulnerabilità indotta da perturbazione testuale minima (Text similarity = 0.943).*



(a) *Immagine originale*



(b) *Immagine perturbata (SSIM = 0.985)*



(c) *Differenza amplificata $\times 15$*

Figura 4.5: *Esempio di campione #175 - vulnerabilità indotta dalla perturbazione visiva minima raggiunta (SSIM = 0.985).*



(a) *Immagine originale*



(b) *Immagine perturbata (SSIM = 0.994)*



(c) *Differenza amplificata $\times 15$*

Figura 4.6: *Esempio di campione #55 - inversione di predizione multimodale True $\rightarrow$ False.*

Capitolo 5

Conclusioni e Sviluppi Futuri

5.1 Sintesi dei risultati

Il presente lavoro ha indagato la robustezza di un modello multimodale di tipo OpenCLIP ViT-B/16 (variante di Themis [29]) rispetto a perturbazioni avversarie applicate alle due modalità sia singolarmente che combinate. L'approccio, interamente white-box, ha consentito di analizzare con precisione il comportamento interno del modello, permettendo l'applicazione diretta dell'attacco PGD sulle rappresentazioni visive e l'utilizzo controllato di un modello linguistico per generare riscritture avversarie coerenti.

I risultati ottenuti evidenziano una netta differenza tra le vulnerabilità unimodali e quelle multimodali. Le perturbazioni testuali da sole hanno avuto un impatto contenuto ($ASR = 0.121$), segno che il modello mantiene una buona robustezza semantica. Al contrario, gli attacchi visivi, anche se impercettibili, hanno causato un collasso quasi completo delle prestazioni ($ASR = 0.864$). Quando le perturbazioni sono state applicate simultaneamente su entrambe le modalità, l' ASR è salito fino a 0.992, con un incremento del 720% rispetto all'attacco testuale e del 12.8% rispetto all'attacco visivo.

Tali evidenze dimostrano che la vulnerabilità multimodale non deriva da un semplice effetto additivo, ma da un'interazione non lineare tra rappresentazioni linguistiche e visive.

Le perturbazioni coordinate, pur mantenendo alta similitudine strutturale e semantica, riescono a spingere la rappresentazione congiunta del modello oltre i confini decisionali, evidenziando la fragilità del meccanismo di fusione.

Gli esperimenti qualitativi confermano inoltre che queste inversioni di predizione si verificano in entrambe le direzioni ($False \rightarrow True$ e $True \rightarrow False$), mostrando come **perturbazioni realistiche possano indurre sia la validazione di contenuti falsi che la censura di contenuti veri**.

5.2 Sviluppi futuri

Sebbene i risultati ottenuti abbiano validato la metodologia proposta, il lavoro apre numerose direzioni di ricerca e miglioramento:

- **Estensione a scenari black-box:** attualmente l'attacco è stato eseguito in modalità white-box, con accesso completo ai pesi, ai gradienti e all'architettura del modello. Un'evoluzione naturale consiste nel testare la trasferibilità della pipeline in contesti black-box, dove molteplici sfide insorgono, come le perturbazioni che devono essere inferite tramite query limitate al modello target; CAMOUFLAGE [2].
- **Generalizzazione ad altri modelli multimodali:** il framework è stato sviluppato specificamente per Themis, ma la sua architettura modulare consente un adattamento agevole ad altri modelli, come BLIP, LLaVA o CLIP-based architectures, per valutarne la robustezza comparata.
- **Aumento della capacità computazionale:** la sperimentazione è stata condotta su CPU, con tempi medi di circa 15 ore per esperimento. L'impiego di GPU o cluster distribuiti permetterebbe di ampliare i dataset, testare configurazioni di attacco più complesse e valutare metriche più granulari (ad esempio, a livello di feature o la specifica robustezza del livello).
- **Analisi diagnostica della vulnerabilità:** un'estensione importante riguarda la localizzazione delle fragilità del modello. Analizzare dove e come la decisione inizia a divergere, nei singoli encoder o nello strato di fusione, consentirebbe di progettare strategie di difesa mirate.
- **Sviluppo di difese multimodali:** sulla base delle evidenze emerse, le strategie di difesa dovrebbero operare a livello di fusione cross-modale, integrando meccanismi di detection o regolarizzazione che penalizzino la diffe-

renza tra rappresentazioni linguistiche e visive in presenza di perturbazioni coordinate.

5.3 Riflessioni conclusive

Questo studio ha rivelato che la complessità della multimodalità, sebbene migliori la comprensione del contesto, espone i modelli a nuove vulnerabilità. Le perturbazioni coordinate non solo ingannano il sistema, ma lo fanno in modo coerente e realistico, mantenendo alta la similarità semantica e percettiva.

La pipeline proposta offre un punto di partenza concreto per valutare la robustezza multimodale in ambienti controllati. Grazie all'uso di strumenti open-source e modelli eseguibili localmente, la sua semplicità e portabilità dimostrano che l'analisi avversaria può essere condotta anche senza grandi risorse, a beneficio della ricerca aperta e replicabile.

Guardando al futuro, l'obiettivo non è solo rendere i modelli più resistenti, ma anche più interpretabili e affidabili. Comprendere come e perché una piccola incoerenza visivo-testuale possa influenzare la decisione di un sistema è il primo passo verso lo sviluppo di modelli multimodali veramente **robusti, trasparenti e sicuri**.

Bibliografia

- [1] Sara Abdali, Sina shaham, and Bhaskar Krishnamachari. Multi-modal misinformation detection: Approaches, challenges and opportunities, 2024.
- [2] Mazal Bethany, Nishant Vishwamitra, Cho-Yu Jason Chiang, and Peyman Najafirad. Camouflage: Exploiting misinformation detection systems through llm-driven adversarial claim transformation, 2025.
- [3] Nicholas Carlini and David Wagner. Towards evaluating the robustness of neural networks. In *2017 IEEE Symposium on Security and Privacy (SP)*, pages 39–57, 2017.
- [4] Chun Wai Chiu, Linghan Huang, Bo Li, Huaming Chen, and Kim-Kwang Raymond Choo. ‘do as i say not as i do’: A semi-automated approach for jailbreak prompt attack against multimodal llms, 2025.
- [5] Javid Ebrahimi, Anyi Rao, Daniel Lowd, and Dejing Dou. Hotflip: White-box adversarial examples for text classification, 2018.
- [6] Logan Engstrom, Andrew Ilyas, Shibani Santurkar, Dimitris Tsipras, Brandon Tran, and Aleksander Madry. Adversarial robustness as a prior for learned representations, 2019.
- [7] Kevin Eykholt, Ivan Evtimov, Earlene Fernandes, Bo Li, Amir Rahmati, Chaowei Xiao, Atul Prakash, Tadayoshi Kohno, and Dawn Song. Robust physical-world attacks on deep learning visual classification. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1625–1634, 2018.
- [8] Siddhant Garg and Goutham Ramakrishnan. Bae: Bert-based adversarial examples for text classification. In *Proceedings of the 2020 Conference on*

Empirical Methods in Natural Language Processing (EMNLP). Association for Computational Linguistics, 2020.

- [9] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples, 2015.
- [10] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations, 2019.
- [11] Di Jin, Zhijing Jin, Joey Tianyi Zhou, and Peter Szolovits. Is bert really robust? a strong baseline for natural language attack on text classification and entailment. In *Proceedings of the AAAI conference on artificial intelligence*, volume 34, pages 8018–8025, 2020.
- [12] Jinfeng Li, Shouling Ji, Tianyu Du, Bo Li, and Ting Wang. Textbugger: Generating adversarial text against real-world applications. In *Proceedings 2019 Network and Distributed System Security Symposium, NDSS 2019*. Internet Society, 2019.
- [13] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks, 2019.
- [14] Seyed-Mohsen Moosavi-Dezfooli, Alhussein Fawzi, and Pascal Frossard. Deepfool: A simple and accurate method to fool deep neural networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
- [15] Davide Antonio Mura, Marco Usai, Andrea Loddo, Manuela Sanguinetti, Luca Zedda, Cecilia Di Ruberto, and Maurizio Atzori. Is it fake or not? a comprehensive approach for multimodal fake news detection. *Online Social Networks and Media*, 47:100314, 2025.
- [16] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32, 2019.

- [17] Samuele Poppi, Tobia Poppi, Federico Cocchi, Marcella Cornia, Lorenzo Baraldi, and Rita Cucchiara. Safe-clip: Removing nsfw concepts from vision-and-language models, 2024.
- [18] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision, 2021.
- [19] Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*, 2019.
- [20] Shivangi Singhal, Rajiv Ratn Shah, Tanmoy Chakraborty, Ponnurangam Kumaraguru, and Shin’ichi Satoh. Spotfake: A multi-modal framework for fake news detection. In *2019 IEEE Fifth International Conference on Multimedia Big Data (BigMM)*, pages 39–47, Sep. 2019.
- [21] David G Stork, Richard O Duda, Peter E Hart, and D Stork. Pattern classification. *A Wiley-Interscience Publication*, 1:281–297, 2001.
- [22] Jiawei Su, Danilo Vasconcellos Vargas, and Kouichi Sakurai. One pixel attack for fooling deep neural networks. *IEEE Transactions on Evolutionary Computation*, 23(5):828–841, October 2019.
- [23] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian Goodfellow, and Rob Fergus. Intriguing properties of neural networks, 2014.
- [24] Florian Tramèr, Alexey Kurakin, Nicolas Papernot, Ian Goodfellow, Dan Boneh, and Patrick McDaniel. Ensemble adversarial training: Attacks and defenses, 2020.
- [25] Le Wang, Zonghao Ying, Tianyuan Zhang, Siyuan Liang, Shengshan Hu, Mingchuan Zhang, Aishan Liu, and Xianglong Liu. Manipulating multimodal agents via cross-modal prompt injection, 2025.
- [26] Zhou Wang, Alan C Bovik, Hamid R Sheikh, and Eero P Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612, 2004.

- [27] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Remi Louf, Morgan Funtowicz, et al. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations*, pages 38–45, 2020.
- [28] Ziyi Yin, Muchao Ye, Tianrong Zhang, Tianyu Du, Jinguo Zhu, Han Liu, Jinghui Chen, Ting Wang, and Fenglong Ma. Vlattack: Multimodal adversarial attacks on vision-language tasks via pre-trained models, 2024.
- [29] Luca Zedda, Alessandra Perniciano, Andrea Loddo, Cecilia Di Ruberto, Manuela Sanguinetti, and Maurizio Atzori. Snarci at semeval-2024 task 4: Themis model for binary classification of memes. In *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*, pages 853–858, 2024.
- [30] Xinyi Zhou, Apurva Mulay, Emilio Ferrara, and Reza Zafarani. Recovery: A multimodal repository for covid-19 news credibility research. In *Proceedings of the 29th ACM international conference on information & knowledge management*, pages 3205–3212, 2020.

Elenco delle figure

2.1	Robustezza e generalizzazione di CLIP rispetto ai modelli supervisionati. A sinistra, l'asse delle x rappresenta l'accuratezza media (<i>top-1</i>) su classi di ImageNet, mentre l'asse y mostra l'accuratezza media su sette dataset che introducono variazioni naturali di distribuzione. A destra viene illustrato un esempio specifico per la classe "banana", comune a cinque dei sette dataset analizzati. Dati tratti e adattati da CLIP [18].	8
2.2	Esempio di generazione di un esempio avversario con il Fast Gradient Sign Method (FGSM). Nonostante la variazione sia invisibile all'occhio umano, il modello GoogLeNet (Szegedy et al., 2014) modifica completamente la sua classificazione. Figura tratta e adattata da Goodfellow et al. [9].	9
2.3	Schema pipeline CAMOUFLAGE. Schema tratto e adattato da CAMOUFLAGE [2].	14
4.1	Pipeline sperimentale. Schema ad alto livello della procedura di valutazione della robustezza multimodale: il sistema esegue le predizioni sui dati puliti, genera perturbazioni testuali e visive, costruisce le versioni multimodali corrotte e calcola infine le metriche di performance e robustezza per ciascuno scenario. . . .	33
4.2	Confronto tra le matrici di confusione nei quattro scenari di valutazione: clean, text corruption, image corruption e multimodal corruption.	37
4.3	Esempio di campione #21 - inversione di predizione multimodale <i>False</i> $\rightarrow$ <i>True</i>	46
4.4	Esempio di campione #167 - vulnerabilità indotta da perturbazione testuale minima (Text similarity = 0.943).	47

4.5	Esempio di campione #175 - vulnerabilità indotta dalla perturbazione visiva minima raggiunta (SSIM = 0.985).	48
4.6	Esempio di campione #55 - inversione di predizione multimodale <i>True</i> $\rightarrow$ <i>False</i>	49

Elenco delle tabelle

2.1	Risultati principali riportati da CAMOUFLAGE [2]. La tabella mostra l'Attack Success Rate (ASR) e l'abbassamento delle prestazioni di retrieval su diversi sistemi di misinformation detection multimodale. I risultati evidenziano come le riscritture LLM-guidate possano compromettere pipeline evidence-based anche in setting black-box.	10
2.2	Esempi di risultati riportati in letteratura per attacchi.	16
4.1	Metriche di classificazione nei diversi scenari.	35
4.2	Metriche di robustezza per le tre tipologie di perturbazione. . . .	36

Risorse aggiuntive

Il codice sorgente, gli script e le risorse utilizzate per la sperimentazione sono disponibili pubblicamente nella seguente repository GitHub: <https://github.com/demon-prin/RobustnessMultimodal>.

La repository include lo script principale per l'esecuzione degli esperimenti, dunque anche la pipeline completa per la generazione delle perturbazioni visive e testuali, le metriche di valutazione e gli strumenti per l'analisi quantitativa e qualitativa dei risultati.

All'interno della repository sono inoltre fornite le istruzioni per:

- installare le dipendenze necessarie;
- eseguire lo script principale in ambiente locale;
- personalizzare i parametri di attacco.

Il dataset impiegato è ReCOVery [30], disponibile al seguente indirizzo: <https://github.com/apurvamulay/ReCOVery>.

Il quale è stato adattato secondo le modifiche introdotte nel progetto: <https://github.com/demon-prin/Is-It-Fake-Or-Not> [15]

I pesi del modello di riferimento non sono pubblicamente disponibili, ma possono essere addestrati o richiesti separatamente.

Tutti i dettagli tecnici per la preparazione dell'ambiente e la riproduzione completa degli esperimenti sono descritti nella documentazione della repository.

Ringraziamenti

Vorrei sfruttare questo capitolo per esprimere i doverosi ringraziamenti a tutti coloro che hanno reso possibile la conclusione di questo mio percorso e la stesura di questa tesi.

Durante questi cinque anni accademici, ho seguito molte lezioni, ho ricevuto numerosi concetti teorici e sostenuto parecchi esami, ma ciò che porterò sempre con me sarà il cuore di questo dipartimento. Pertanto, vorrei ringraziare tutti i professori, i ricercatori, i dottorandi e i colleghi del Dipartimento di Matematica e Informatica con cui ho avuto il piacere di confrontarmi e lavorare. Tutti voi avete contribuito a farmi vivere in un magnifico ambiente universitario e, soprattutto, mi avete insegnato quanto sia importante dare il proprio contributo quando ciò che si fa è ciò che si ama, a prescindere dalle condizioni.

Ogni qualvolta mi sia ritrovato a confrontarmi con un docente, ho sempre ricevuto lo stesso rispetto che davo, se non di più. Questa professionalità che ho riscontrato nel nostro dipartimento non l'ho mai trovata da nessun'altra parte, per questo rimarrà per sempre un valore che mi porterò dietro.

Vorrei dedicare un piccolo spazio di ringraziamenti al gruppo di ricerca che mi ha accolto per lo svolgimento di questo lavoro e la stesura di questa tesi. Innanzitutto vorrei ringraziare Davide Mura con cui ho avuto il piacere di lavorare durante questo progetto. Vorrei ringraziare il Dottor Andrea Loddo che ha saputo farmi inserire al meglio all'interno di questo progetto grazie al suo ottimo Reading Course. Infine, ci terrei a ringraziare il Professor Maurizio Atzori, che ha supervisionato il mio lavoro e mi ha dato la possibilità avvicinarmi a questo splendido progetto, con l'augurio di continuarlo e concluderlo nel migliore dei modi. Grazie.

