



UNIVERSITÀ DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

**Relazione - Sperimentazione di metodologie di
Multimodal Deep Learning per l'analisi di dati
testuali e visuali**

Prestatore d'opera

Dott. Davide Cocco

Premessa e obiettivi

Nella presente relazione è presente una descrizione generica del lavoro svolto nell'ambito della **Sperimentazione di metodologie di Multimodal Deep Learning per l'analisi di dati testuali e visivi** con particolare focus su un modello di fake news detection.

Ai fini di dare un contributo scientifico sullo studio della robustezza dei modelli multimodali, l'obiettivo principale è stato quello di portare avanti le sperimentazioni iniziate durante il percorso accademico, in particolare per la tesi di laurea magistrale del sottoscritto dal titolo: **Cross-Modal Vulnerability: Exploiting Fusion Fragility in Multimodal Misinformation Detection with Adversarial Examples**

Setup sperimentale

Modello e dati

Il modello preso in considerazione è **Themis**, sviluppato in collaborazione con i gruppi di ricerca appartenenti al dipartimento di Matematica e Informatica dell'Università degli Studi di Cagliari. Il suddetto modello è basato su OpenCLIP e TinyLlama ed è stato impiegato per la classificazione binaria di news (vere/false) classificandosi in ottima posizione alle challenge a cui ha partecipato.

Gli esperimenti sono stati condotti principalmente sul test set del dataset ReCOVery e hanno analizzato la robustezza del modello sotto gli attacchi avversari in diverse configurazioni.

Perturbazioni

Le perturbazioni visive sono state generate tramite **Projected Gradient Descent (PGD)**, con vincoli tali da mantenere elevata la similarità percettiva ($SSIM > 0.95$).

Nella tesi le perturbazioni testuali sono state ottenute tramite parafrasi generate da un modello linguistico leggero, mantenendo alta la coerenza semantica (similarità coseno elevata). Durante queste nuove sperimentazioni è stato implementato **BertAttack** per permettere una perturbazione mirata e più efficace anche della parte testuale delle news cercando sempre di mantenere alta similarità tra i testi.

Configurazioni considerate

Al fine di analizzare il comportamento del modello in diversi scenari decisionali, sono state considerate differenti configurazioni di inferenza. In particolare, è stata confrontata l'inferenza multimodale nativa (**Multimodale Cross**), basata sulla fusione congiunta di testo e immagine

all'interno del modello Themis, con configurazioni unimodali (solo testo e solo immagine) e con strategie di fusione a posteriori.

Queste ultime combinano i punteggi dei modelli unimodali secondo tre modalità: media (*mean*), minimo (*min*) e massimo (*max*). Tale confronto consente di isolare il contributo delle singole modalità e valutare il trade-off tra performance e robustezza rispetto all'approccio multimodale profondo.

Pipeline e metriche

La pipeline sperimentale prevede una prima fase di inferenza su dati clean, seguita dalla selezione dei campioni correttamente classificati, sui quali vengono applicate le perturbazioni avversarie. Successivamente, viene effettuata una nuova inferenza sui dati corrotti e i risultati vengono confrontati con quelli originali.

Le perturbazioni vengono generate separatamente sulle due modalità (testo e immagine) e successivamente combinate per valutare scenari di attacco unimodale e multimodale.

Le metriche utilizzate includono:

- **Accuracy, Precision, Recall, F1-score**
- **AUC** (Area Under the ROC Curve)
- **Attack Success Rate (ASR)**: proporzione di campioni inizialmente corretti che vengono classificati erroneamente dopo l'attacco
- **Flip Rate**: percentuale di predizioni modificate
- **Delta Accuracy**: differenza tra accuracy clean e corrotta

Nel caso di attacchi mirati (fake $\rightarrow$ real), l'ASR viene calcolato considerando esclusivamente i campioni della classe fake correttamente classificati nel caso clean.

Risultati principali

Curve ROC

In Figura 1 e Figura 2 sono riportate le curve ROC per le diverse configurazioni rispettivamente su dati clean e perturbati.

Dall'analisi delle curve ROC emerge chiaramente che il modello multimodale cross rappresenta la configurazione più performante in condizioni ideali (dati clean), confermando l'efficacia della fusione multimodale nel migliorare la capacità discriminativa.




Figura 1: *Curve ROC su dati clean*

Tuttavia, il comportamento del modello cambia significativamente in presenza di perturbazioni. Quando viene corrotta una sola modalità, il modello mantiene una buona capacità di classificazione, mostrando una certa resilienza. Al contrario, quando entrambe le modalità vengono perturbate simultaneamente, si osserva un drastico degrado delle prestazioni, con un comportamento prossimo al caso randomico.

Tabella riassuntiva

Configurazione	AUC Clean	AUC Txt Corr	AUC Img Corr	AUC Multi Corr
Multimodale Cross	0.988	0.946	0.883	0.519
Fusion Mean	0.929	0.897	0.498	0.820
Fusion Min	0.931	0.897	0.498	0.821
Fusion Max	0.837	0.897	0.498	0.586

Tabella 1: *Confronto delle AUC nelle diverse configurazioni*




Figura 2: Curve ROC su dati perturbati

L'analisi quantitativa mostra che il modello multimodale cross raggiunge le migliori performance su dati clean ($AUC = 0.988$), ma perde significativamente robustezza in presenza di perturbazioni multimodali. Al contrario, le strategie di fusione a posteriori (mean e min) mantengono valori di AUC più elevati sotto attacco, suggerendo che fusioni più semplici possano risultare più stabili rispetto alla fusione multimodale profonda.

Analisi e implicazioni

I risultati evidenziano una fragilità intrinseca della fusione multimodale. Le perturbazioni sulle singole modalità degradano le performance solo parzialmente, mentre la combinazione di perturbazioni testuali e visive porta a un collasso significativo del modello.

L'analisi dei grafici scatter suggerisce inoltre che le vulnerabilità testuali e visive colpiscano campioni differenti, aumentando la superficie di attacco complessiva. Questo mette in evidenza

un trade-off rilevante: la multimodalità migliora le prestazioni in condizioni ideali, ma può ridurre la robustezza in scenari avversari.

Conclusioni e sviluppi futuri

Il lavoro svolto ha permesso di approfondire il comportamento dei modelli multimodali sotto attacco avversario, evidenziando come le migliori performance su dati clean non coincidano necessariamente con una maggiore robustezza.

I risultati ottenuti mostrano fenomeni coerenti e facilmente interpretabili, suggerendo la necessità di ulteriori analisi su modelli, dataset e strategie di difesa differenti. In particolare, il confronto tra multimodalità profonda e fusioni unimodali a posteriori rappresenta un aspetto promettente sia dal punto di vista applicativo sia dal punto di vista scientifico, con possibili sviluppi verso una futura pubblicazione.